

Báo cáo Kiểm thử Hiệu năng Hệ thống AI Text-to-SQL

Load Test với k6 — Ứng dụng Vanna (Ollama llama3.2 + PostgreSQL Neon)

Đức Anh

ducanhtrungvan@gmail.com

Ngày 04 tháng 08 năm 2026

Abstract

Báo cáo trình bày kết quả kiểm thử hiệu năng (load test) của hệ thống hỏi đáp dữ liệu bằng ngôn ngữ tự nhiên (Text-to-SQL) xây dựng trên nền Vanna, sử dụng mô hình ngôn ngữ lớn Ollama llama3.2 chạy cục bộ và cơ sở dữ liệu PostgreSQL (Neon). Công cụ **k6** được dùng để mô phỏng số lượng người dùng đồng thời tăng dần (5, 15, 30 và 50 người dùng). Kết quả cho thấy hệ thống hoạt động ổn định dưới **10 người dùng đồng thời**, nhưng **bão hoà** khi vượt ngưỡng này: thông lượng (throughput) không tăng thêm mà độ trễ và tỉ lệ lỗi tăng phi tuyến. Ở mức 50 người dùng, độ trễ p95 đạt **139 giây** và tỉ lệ lỗi lên tới **13%**.

1 Mục tiêu

Đánh giá khả năng chịu tải của endpoint hỏi đáp AI khi số lượng người dùng đồng thời tăng cao, xác định *điểm bão hoà* và đề xuất hướng cải thiện.

2 Môi trường và phương pháp

Lưu ý kỹ thuật: Mỗi câu hỏi kích hoạt **2 lần gọi mô hình ngôn ngữ** (một lần để sinh câu lệnh SQL, một lần để diễn giải kết quả). Mỗi request dùng một `conversation_id` riêng biệt nhằm tránh cơ chế khoá theo hội thoại (HTTP 409) của máy chủ.

3 Kịch bản kiểm thử

Hai kịch bản tăng tải (ramping-vus) được thực hiện:

- **Kịch bản A — Tăng dần:** 5 → 15 → 30 người dùng đồng thời trong ≈ 3 phút 35 giây.
- **Kịch bản B — Cao điểm 50:** tăng lên 50 người dùng và giữ trong 120 giây.

Hạng mục	Chi tiết
Công cụ kiểm thử	k6 v2.1.0 (Windows/amd64)
Endpoint	POST /api/vanna/v2/chat_sse (streaming SSE)
Mô hình AI	Ollama llama3.2 (chạy cục bộ)
Cơ sở dữ liệu	PostgreSQL — Neon (qlsp_backup)
Máy chủ ứng dụng	Uvicorn (1 worker), FastAPI
Loại truy vấn	Câu hỏi tiếng Việt (đếm / tổng hợp)
Tiêu chí thành công	HTTP 200 và stream kết thúc bằng [DONE]
Timeout mỗi request	180 giây
Baseline (1 người dùng)	$\approx$ 2,5 giây/truy vấn

Table 1: Cấu hình môi trường kiểm thử.

4 Kết quả tổng hợp

Chỉ số	1 user (baseline)	30 user (A)	50 user (B)
Tổng số request	1	177	132
Thông lượng (req/giây)	0,40	0,75	0,70
Tỉ lệ thành công	100%	95,0%	87,0%
Số lỗi (rớt kết nối / EOF)	0	9	17
Tỉ lệ lỗi HTTP	0%	5,0%	13,0%

Table 2: So sánh kết quả tổng quan theo mức tải.

Thời gian phản hồi AI	Baseline	30 user	50 user
Nhanh nhất (min)	—	0,59 s	1,34 s
Trung vị (median)	2,5 s	19,43 s	23,26 s
Trung bình (avg)	2,5 s	20,90 s	36,28 s
p90	—	32,71 s	108,40 s
p95	—	55,11 s	139,16 s
Chậm nhất (max)	2,5 s	89,28 s	157,20 s

Table 3: Phân bố thời gian phản hồi AI theo mức tải (đơn vị: giây).

5 Phân tích

5.1 Thông lượng đạt trần

Thông lượng gần như không đổi giữa 30 và 50 người dùng (0,75 so với 0,70 req/giây). Điều này cho thấy hệ thống đã **đạt trần xử lý** ở mức $\approx$ 0,7–0,75 request/giây. Việc tăng

thêm người dùng *không* làm tăng thông lượng mà chỉ kéo dài hàng đợi, khiến độ trễ và tỉ lệ lỗi tăng vọt.

5.2 Nút thắt cổ chai: mô hình ngôn ngữ cục bộ

Nguyên nhân chính là **Ollama chạy cục bộ xử lý gần như tuần tự**. Với 2 lần gọi LLM cho mỗi câu hỏi, khi có 30–50 người dùng cùng lúc, các yêu cầu xếp hàng dài: thời gian phản hồi tăng từ 2,5 giây (1 người) lên trung vị $\approx$ 23 giây và p95 tới 139 giây (50 người) — tức chậm gấp **hơn 50 lần**.

5.3 Lỗi rớt kết nối

Các lỗi đều thuộc dạng EOF (máy chủ đóng kết nối khi quá tải). Tỉ lệ lỗi tăng từ 5% (30 người) lên 13% (50 người), do kết hợp: hàng đợi Ollama, giới hạn kết nối tới Neon, và Uvicorn chỉ chạy **một worker** duy nhất.

6 Kết luận

Điểm bão hoà của hệ thống hiện tại $\approx$ 5–10 người dùng đồng thời.

Dưới 10 người dùng: phản hồi nhanh, gần như không lỗi. Từ 15 người dùng: độ trễ tăng phi tuyến, bắt đầu rớt kết nối. Ở 30–50 người dùng: p95 đạt 55–139 giây và 5–13% request thất bại — **không đạt trải nghiệm chấp nhận được** cho người dùng thực.

7 Khuyến nghị

Ưu tiên	Giải pháp	Kỳ vọng
Cao	Chạy Uvicorn nhiều worker (<code>--workers 4</code>) hoặc dùng Gunicorn	Giảm rớt kết nối
Cao	Tăng song song Ollama (<code>OLLAMA_NUM_PARALLEL</code>) hoặc chuyển sang API cloud (Anthropic/OpenAI) cho tải cao	Gỡ nút thắt LLM
TB	Cache câu hỏi và câu lệnh SQL lặp lại	Giảm số lần gọi LLM
TB	Cấu hình connection pool tới Neon hợp lý, tăng timeout	Giảm lỗi EOF
Thấp	Thêm hàng đợi và thông báo “đang xử lý” cho người dùng	Cải thiện trải nghiệm khi tải cao

Báo cáo được lập dựa trên số liệu thực đo từ k6 (`k6_summary.json`, `k6_summary_50.json`).
Kịch bản kiểm thử: `loadtest/ai_load_test.js`.